

Reporte de avance — Hackathon 2026

Equipo: KingsCode

Integrantes: Esteban Alejandro Hernández · Luis Sebastián Contreras Díaz

Fecha de la medición: 2 de octubre de 2026 (RTX 4090, sala Turing)

1. Puntaje sobre las preguntas de muestra

Resultado de `python scripts/evaluate.py --submission submissions_sample50.jsonl --split sample` (50 filas, 0 errores de validación, sha256 e2041f84..., en el repositorio del equipo: docs/entrega_viernes/; generado automáticamente por el pipeline con esta configuración sobre las salidas guardadas del modelo).

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas	12,00 (9/15)	20
Calidad de citación	17,55 (recall ponderado 0,878; 0 % citas sin respaldo)	20
Abstención calibrada	7,91 (0 abstenciones; 34/43 respuestas correctas)	10
Total automático sin RAGAS	37,46	50

Observaciones sobre el resultado:

Subimos de 26,63 (1-oct) a 37,46 cambiando una variable por corrida. El resultado se reprodujo idéntico en dos computadores y la verificación en vivo simulada (regenerar 3 preguntas) coincide en normas y pasajes. Con `--ragas` (juez oficial, una medición) obtuvimos correctness 0,4275 (referencia 0,451) sobre una corrida previa de 35,18, que con RAGAS sumó 48,00/80; los cambios posteriores no tocan el texto que lee el juez. Probados y descartados con datos: recuperación híbrida + reranker + locator (36,59 y 19 s/pregunta) y ALIA Legal 7B (formato inválido).

2. Estado del corpus

Métrica	Valor
Documentos incorporados	172: 163 del corpus base + 9 añadidos por análisis de fallas (Ley 472 de 1998, 4 sentencias de la Corte Suprema, 3 de unificación y constitucionalidad, 1 ley)
Fragmentos indexados	26.504, uno por artículo o unidad de sentencia
Áreas del banco con cobertura	10/10: constitucional 43 docs, familia 29, laboral 25, civil 24, administrativo 19, tributario 18, penal 16, comercial 14, mercados 14, procesal 10
Áreas del banco sin cobertura	Ninguna; procesal y la jurisprudencia del Consejo de Estado son lo más delgado

Fuentes consultadas: relatoría de la Corte Constitucional (96), Función Pública – Gestor Normativo (69), Corte Suprema de Justicia (5), normograma del SENA (Código Civil), Comunidad Andina (1). Cada documento conserva URL, fecha de consulta y SHA-256; hoy las 172 URLs responden.

3. Arquitectura actual

Componente	Elección
Encoder	Qwen/Qwen3-Embedding-0.6B (abierto, revisión fijada); BM25 queda como recuperador principal porque supera al híbrido en puntaje por tiempo
Decoder	Qwen/Qwen3-8B, BF16, temperatura 0, decodificación greedy, sin "thinking"
Estrategia de recuperación	BM25 por artículo + expansión por grafo normativo (59 mil nodos) activada por un router; en cerradas, una consulta por opción fusionada por RRF; 8 pasajes
Segmentación del corpus	Estructural jurídica: norma → título → artículo (sentencias por unidad), con norma, artículo y jerarquía en los metadatos
Mecanismo de abstención	Política sobre la evidencia (vacía, en conflicto o no vigente) + abstención del modelo; antes de abstenerse, una guarda determinista repara o suprime cada cita no respaldada

4. Riesgos identificados

- Corrección del texto libre (RAGAS 0,43 frente a 0,45).** El análisis por categoría muestra respuestas que discuten la evidencia en vez de responder, citas reales que no sostienen la afirmación ($\approx 11\%$ en una medición léxica) y respuestas de más del doble de la extensión esperada (23 %). Mitigación: un prompt con método jurídico (área y eje, jerarquía, especialidad, vigencia, regla y excepción, control de distractores en cerradas, datos exactos y extensión según la pregunta), que medimos sin crédito con un proxy local antes de una única medición con el juez.
- Normas que la pregunta no nombra (3 de 41 fundamentos no se recuperan).** Mitigación: consultas adicionales generadas por el propio Qwen para texto libre y un tope de pasajes por documento; se adoptan solo si mejoran el puntaje sin pasar de 5 h para 992 preguntas.
- Tiempo y reproducibilidad el sábado.** Hoy son 16,4 s/pregunta ($\approx 4,5$ h de una ventana de 6 h) y las fuentes oficiales cambian al volver a descargarlas (67 de 163). Mitigación: corpus e índice congelados como un único snapshot con hashes en ambas máquinas, ejecución con puntos de control y reanudación, y la posibilidad de repartir las 992 preguntas entre dos GPU si la salida es idéntica byte a byte.